

머신러닝 데이터 전처리·EDA 핵심 순서

0. 데이터 불러오기

```
pd.read_csv()
```

1. 데이터 기본 구조 확인

데이터 생김새

```
df.head()  
df.tail()
```

행·열 개수

```
df.shape
```

컬럼 이름

```
df.columns
```

데이터 타입 / 결측치 기본 확인

```
df.info()
```

기초 통계량

```
df.describe()
```

확인할 것

- 데이터가 몇 행인가?
 - 변수가 몇 개인가?
 - 숫자형 / 문자형 변수는 무엇인가?
 - 값의 범위가 이상하지 않은가?
-

2. 결측치 확인

```
df.isnull().sum()
```

또는

```
df.isna().sum()
```

처리

```
df.dropna()  
df.fillna()
```

확인할 것

- 어떤 컬럼에 결측값이 있는가?
 - 결측값이 너무 많은 변수는 없는가?
-

3. 중복 데이터 확인

```
df.duplicated().sum()
```

제거

```
df.drop_duplicates()
```

4. 변수별 값 확인

특히 범주형 변수 확인에 중요.

```
df['컬럼'].unique()  
df['컬럼'].nunique()  
df['컬럼'].value_counts()
```

예:

```
df['사기유형'].value_counts()
df['연령대'].value_counts()
```

확인할 것

- 범주가 어떤 것들이 있는가?
- 오타나 이상한 카테고리가 있는가?
- 특정 범주에 데이터가 지나치게 몰려 있는가?

5. 데이터 분포 확인

히스토그램

```
df.hist()
```

또는

```
plt.hist()
```

박스플롯

```
sns.boxplot()
```

확인할 것

- 값이 어느 구간에 많이 몰려 있는가?
- 분포가 한쪽으로 치우쳐 있는가?
- 이상치가 존재하는가?

6. 이상치 확인

Box Plot

```
sns.boxplot(x=df['컬럼'])
```

대표적으로:

```
피해금액
매출액
소득
```

연령
이용시간

등을 확인.

필요하면:

Q1
Q3
IQR

기준으로 이상치 탐색 가능.

7. 변수 간 관계 시각화

산점도 Scatter Plot

숫자형 X와 Y 관계 확인.

```
plt.scatter()
```

또는

```
sns.scatterplot()
```

예:

광고비 ↔ 매출
연령 ↔ 피해금액
통화시간 ↔ 피해금액

눈으로 선형관계나 패턴이 있는지 먼저 확인.

8. 상관계수 확인 ★

수업에서 중요하게 배운 부분.

```
df.corr()
```

Heatmap

```
sns.heatmap(df.corr(), annot=True)
```

확인할 것

X ↔ y 관계가 강한가?
X ↔ X끼리 너무 비슷하지 않은가?

상관계수는:

+1 강한 양의 관계
0 선형관계 거의 없음
-1 강한 음의 관계

9. Pearson / Spearman 상관검정 ★

Pearson

선형적인 관계 확인.

```
pearsonr()
```

예:

```
from scipy.stats import pearsonr  
  
r, p = pearsonr(df['X'], df['Y'])
```

Spearman

순위·단조 관계 확인.

```
spearmanr()
```

```
from scipy.stats import spearmanr
```

10. p-value 확인 ★

Pearson / Spearman과 함께 확인.

```
r, p = pearsonr(X, Y)
```

보통:

$p < 0.05$

→ 통계적으로 유의한 관계

$p \geq 0.05$

→ 관계가 있다고 보기 어려움

단,

p-value가 작다고 반드시 중요한 변수라는 뜻은 아님.

상관계수 크기도 같이 봐야 함.

11. 범주형 변수 인코딩

머신러닝 모델은 문자를 그대로 처리하지 못하는 경우가 많음.

예:

```
봄  
여름  
가을  
겨울
```

One-Hot Encoding

```
pd.get_dummies()
```

또는

```
OneHotEncoder
```

12. 변수 크기 맞추기 — Scaling

특히 KNN / K-Means / PCA에서는 매우 중요.

StandardScaler

```
StandardScaler()
```

평균 0, 표준편차 1 기준으로 맞춤.

MinMaxScaler

```
MinMaxScaler()
```

보통 0~1 사이로 맞춤.

중요한 이유

예:

```
연령 = 20~80  
피해금액 = 100,000~100,000,000
```

그대로 거리계산하면 피해금액이 모델을 거의 지배할 수 있음.

13. X와 y 분리

독립변수

```
X = df[['변수1', '변수2', '변수3']]
```

목표변수

```
y = df['target']
```

여기서 가장 중요한 질문:

내가 무엇을 예측하려는가?

그게 `y`.

나머지 예측에 사용할 정보가 X.

14. Train / Test 데이터 분리 ★

```
train_test_split()
```

예:

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42
)
```

보통:

```
Train 80%
Test 20%
```

15. 분류 문제라면 클래스 비율 확인 ★

```
y.value_counts()
```

비율까지:

```
y.value_counts(normalize=True)
```

예:

```
정상 95%
사기 5%
```

라면 **Accuracy**만 믿으면 안 됨.

이런 불균형 데이터에서는:

Precision
Recall
F1
ROC-AUC
PR-AUC

등을 봐야 함.

16. 모델 학습 후 변수 중요도 확인

Random Forest / Tree 등:

`model.feature_importances_`

확인 목적:

모델이 어떤 변수를 많이 사용했는가?

예:

피해금액	0.32
통화시간	0.27
연령	0.18
사기유형	0.13

17. 회귀계수 확인

Linear Regression 등:

`model.coef_`

`model.intercept_`

어떤 변수가 Y와

+ 방향인지
- 방향인지

확인 가능.

18. 모델 성능 확인

분류

```
accuracy_score()
precision_score()
recall_score()
f1_score()
confusion_matrix()
classification_report()
roc_auc_score()
```

특히 기억

```
Accuracy  = 전체적으로 얼마나 맞췄나
Precision = 위험이라 한 것 중 진짜 위험은?
Recall    = 실제 위험 중 얼마나 잡았나
F1        = Precision + Recall 균형
```

회귀

```
mean_absolute_error()
mean_squared_error()
r2_score()
```

즉:

```
MAE
MSE
R2
```

19. 교차검증 ★

한 번 Train/Test를 나눈 결과만 믿지 않고 여러 번 검증.

```
cross_val_score()
```

대표:

```
5-Fold Cross Validation
```

모델 선택이나 과적합 확인에 중요.

20. 군집분석을 한다면

K-Means:

```
KMeans()
```

적절한 군집 수 확인

```
model.inertia_
```

그리고:

```
Elbow Method
```

로 K값 결정.

21. PCA를 한다면

먼저:

```
StandardScaler()
```

이후:

```
PCA()
```

정보를 얼마나 보존했는지:

```
explained_variance_ratio_
```

22. 텍스트 유사성을 본다면

TF-IDF

```
TfidfVectorizer()
```

단어 빈도

```
CountVectorizer()
```

유사도

```
cosine_similarity()
```

즉:

문장 A와 문장 B가 얼마나 유사한가?

를 숫자로 계산.

★ 정말 핵심만 외우면

새 데이터 받으면 우선 이 순서로 보면 된다.

- ① df.head()
- ② df.shape
- ③ df.info()
- ④ df.describe()

- ⑤ df.isnull().sum()
- ⑥ df.duplicated().sum()

- ⑦ value_counts()
- ⑧ unique()

- ⑨ histogram
- ⑩ boxplot

- ⑪ scatterplot
- ⑫ df.corr()
- ⑬ heatmap()
- ⑭ pearsonr() / spearmanr()
- ⑮ p-value
- ⑯ get_dummies()
- ⑰ StandardScaler() / MinMaxScaler()
- ⑱ X / y 분리
- ⑲ train_test_split()
- ㉔ 모델 학습
 - Accuracy / Precision / Recall / F1
 - 또는
 - MAE / MSE / R^2
 - cross_val_score()
 - feature_importances_ / coef_

초압축 기억법

구조 → 오류 → 분포 → 관계 → 전처리 → 분리 → 학습 → 검증 → 해석

구조
head / shape / info / describe

↓

오류
isnull / duplicated

↓

분포
value_counts / hist / boxplot

↓

관계
scatter / corr / heatmap
Pearson / Spearman / p-value

↓

전처리

get_dummies / StandardScaler / MinMaxScaler

↓

분리

X / y / train_test_split

↓

학습

fit / predict

↓

검증

Accuracy / F1 / AUC

MAE / MSE / R^2

Cross Validation

↓

해석

feature_importances_

coef_